UNIDAD II — MACHINE LEARNING

Aprendizaje no supervisado, validación de modelos y métricas

2.1 No supervisado · 2.2 Validación con matriz de confusión · 2.3 Sobreajuste / Subajuste · 2.4 Métricas

Contenido de la sesión

2.1 **Aprendizaje no supervisado**
Clustering y reducción de dimensión

2.2 **Validación de modelos**
Matriz de confusión y un caso práctico resuelto

2.3 **Sobreajuste / Subajuste**
Diagnóstico y estrategias de mitigación

2.4 **Métricas de evaluación**
Accuracy, precision, recall, F1 y curva ROC

2.1 — APRENDIZAJE NO SUPERVISADO

El modelo explora los datos sin etiquetas

A diferencia del aprendizaje supervisado, aquí no existe una variable de salida conocida: el algoritmo busca por sí mismo patrones, agrupaciones o estructuras ocultas en los datos.

Objetivo

Descubrir estructura, relaciones o grupos naturales en los datos.

Entrada

Datos sin etiquetar: solo variables de entrada (X), sin la variable objetivo (y).

Aplicaciones

Segmentación de clientes, detección de anomalías, compresión de datos, recomendación.

Técnica: Clustering

Técnica: Reducción de dimensión

2.1 — APRENDIZAJE NO SUPERVISADO

Supervisado vs. no supervisado, y sus enfoques

Aspecto	Supervisado	No supervisado
Datos de entrada	Etiquetados (X, y conocida)	Sin etiquetar (solo X)
Objetivo	Predecir o clasificar una salida conocida	Descubrir estructura o patrones ocultos
Evaluación	Directa: accuracy, precision, recall, error	Indirecta: silueta, inercia (no hay "respuesta correcta")
Ejemplos	Regresión, clasificación	Clustering, reducción de dimensión, anomalías

Principales enfoques dentro del no supervisado

Clustering: por partición (K-Means), por densidad (DBSCAN), jerárquico (dendrogramas)

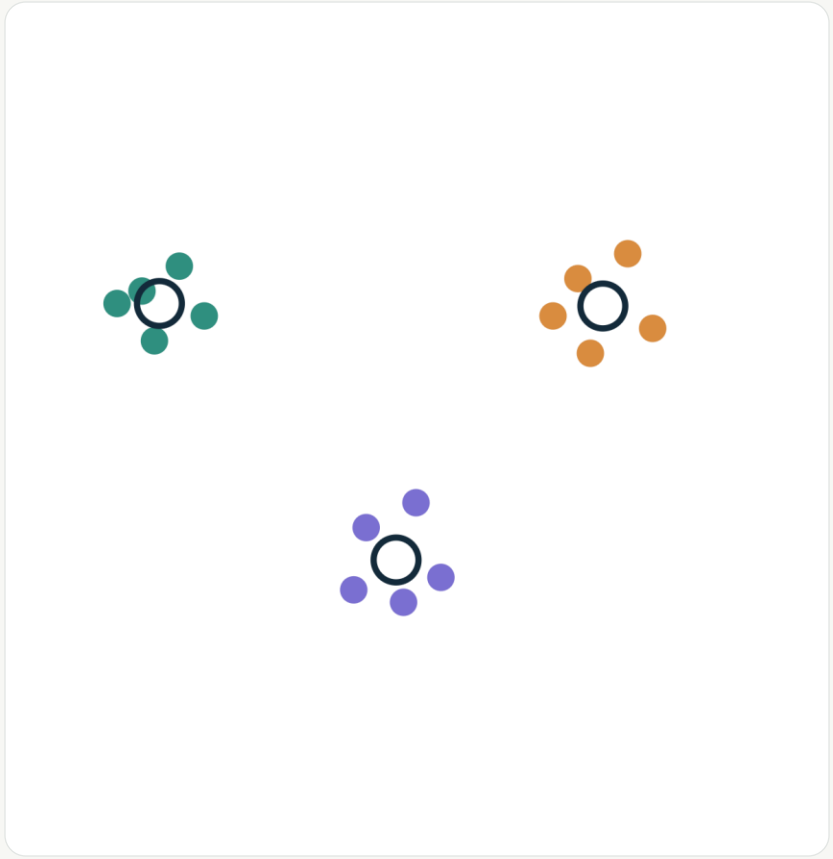
Reducción de dimensión: lineal (PCA), no lineal (t-SNE, UMAP)

Detección de anomalías: identifica puntos que no encajan en ningún grupo

Reglas de asociación: descubre relaciones entre variables (ej. canasta de mercado)

2.1 — CLUSTERING

Agrupar datos similares sin supervisión



Algoritmo K-Means

1. Elegir k, el número de grupos a formar
2. Inicializar k centroides de forma aleatoria
3. Asignar cada punto al centroide más cercano
4. Recalcular cada centroide como el promedio de su grupo
5. Repetir hasta que los centroides no cambien

Otros algoritmos: DBSCAN (basado en densidad), Clustering jerárquico (dendrograma)

2.1 — CLUSTERING

Comparación de algoritmos de agrupamiento

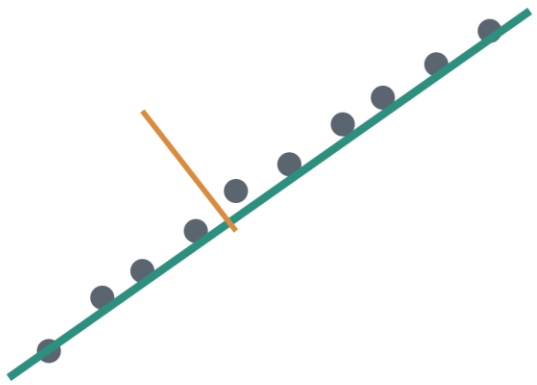
Algoritmo	Cómo funciona	Ventajas	Limitaciones
K-Means	Minimiza la distancia de cada punto a su centroide	Rápido y escalable a grandes volúmenes	Requiere definir k; sensible a outliers y a grupos no esféricos
DBSCAN	Agrupa por densidad de puntos vecinos	No requiere k; detecta formas irregulares y outliers	Sensible a los parámetros eps y minPts; falla con densidades muy distintas
Jerárquico	Construye un árbol (dendrograma) de fusiones sucesivas	No requiere k previo; muestra toda la jerarquía de agrupamiento	Costoso computacionalmente en datasets grandes

¿Cómo elegir k en K-Means? Método del codo

Se grafica la inercia (WCSS: suma de distancias al cuadrado dentro de cada grupo) para distintos valores de k. Se elige el punto donde la mejora empieza a estabilizarse, formando un "codo" en la curva.

2.1 — REDUCCIÓN DE DIMENSIÓN

Menos variables, sin perder información relevante



¿Por qué reducir dimensiones?

Facilita la visualización, reduce el ruido y el tiempo de cómputo, y ayuda a evitar el sobreajuste generado por variables redundantes.

PCA (Análisis de Componentes Principales)

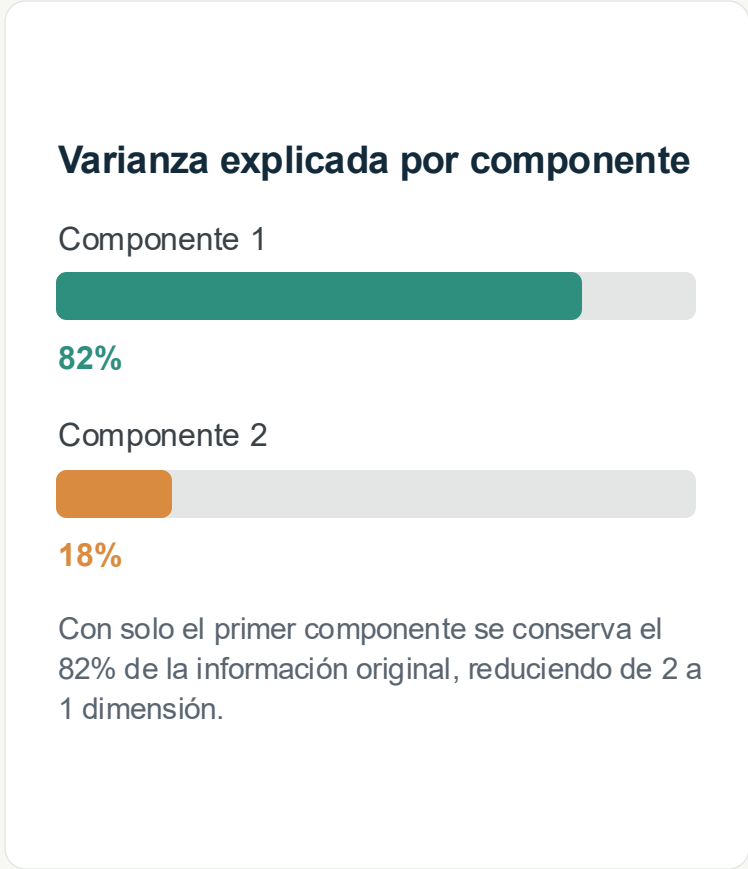
Combina variables correlacionadas en nuevos componentes no correlacionados que capturan la mayor varianza posible de los datos.

Otras técnicas: t-SNE y UMAP, usadas sobre todo para visualización no lineal

2.1 — REDUCCIÓN DE DIMENSIÓN

PCA: el cálculo detrás de la técnica

1. Estandarizar los datos (media 0, varianza 1)
2. Calcular la matriz de covarianza entre las variables
3. Obtener los eigenvectores (autovectores) y eigenvalores (autovalores) de esa matriz
4. Ordenar los eigenvectores según su eigenvalor, de mayor a menor varianza explicada
5. Proyectar los datos sobre los k eigenvectores principales (componentes)



2.2 — VALIDACIÓN DE MODELOS

La matriz de confusión

Tabla que compara las predicciones del modelo con la clase real, y es la base para calcular las métricas de clasificación.

	Predicho: Positivo	Predicho: Negativo
	TP Verdadero Positivo	FN Falso Negativo
	FP Falso Positivo	TN Verdadero Negativo

TP — el modelo predijo positivo y acertó

FP — predijo positivo pero era negativo (Error tipo I)

FN — predijo negativo pero era positivo (Error tipo II)

TN — el modelo predijo negativo y acertó

2.2 — VALIDACIÓN DE MODELOS

¿Cómo se cuentan TP, TN, FP y FN?

Se recorre cada predicción y se compara contra el valor real:

Real Sí + Predicho Sí → **TP** | Real Sí + Predicho No → **FN** | Real No + Predicho Sí → **FP** | Real No + Predicho No → **TN**

Paciente	Real	Predicho	Clasificación
1	Sí	Sí	TP
2	Sí	No	FN
3	No	No	TN
4	No	Sí	FP
5	Sí	Sí	TP
6	No	No	TN

Sumando este conteo para los 100 pacientes: TP = 35, FN = 5, FP = 8, TN = 52

2.2 — CASO PRÁCTICO

Diagnóstico de una enfermedad con IA

Un modelo se evalúa con 100 pacientes: 40 tienen realmente la enfermedad (positivos) y 60 no la tienen (negativos). Al aplicar el modelo se obtiene la siguiente matriz de confusión:

	Predicho: Sí	**Predicho: No**
Real: Sí	35 (TP)	5 (FN)
Real: No	8 (FP)	52 (TN)

Total de pacientes: **100**

Positivos reales: 35 + 5 = **40**

Negativos reales: 8 + 52 = **60**

→ **A partir de esta matriz calculamos las métricas de desempeño**

2.4 — MÉTRICAS DE EVALUACIÓN

Fórmulas aplicadas al caso del diagnóstico

Accuracy (Exactitud)

(TP + TN) / (TP + TN + FP + FN)

(35 + 52) / 100

0.87 (87%)

Precision (Precisión)

TP / (TP + FP)

35 / (35 + 8) = 35 / 43

0.814 (81.4%)

Recall (Sensibilidad)

TP / (TP + FN)

35 / (35 + 5) = 35 / 40

0.875 (87.5%)

F1-score

2 · (Precision · Recall) / (Precision + Recall)

2 · (0.814 · 0.875) / (0.814 + 0.875)

0.843 (84.3%)

Precision responde "¿cuántos de los que predije positivos lo eran de verdad?"; Recall responde "¿cuántos positivos reales detecté?"; F1 equilibra ambas.

2.4 — MÉTRICAS DE EVALUACIÓN

Más allá de las cuatro métricas básicas

Especificidad

TN / (TN + FP) = 52 / 60

0.867 (86.7%)

Qué tan bien detecta el modelo a los negativos reales

Tasa de error

(FP + FN) / Total = (8 + 5) / 100

0.13 (13%)

Equivale a 1 − Accuracy

¿Qué métrica priorizar según el problema?

Priorizar Recall

Cuando un falso negativo es más costoso: no detectar una enfermedad grave, no detectar un fraude

Priorizar Precision

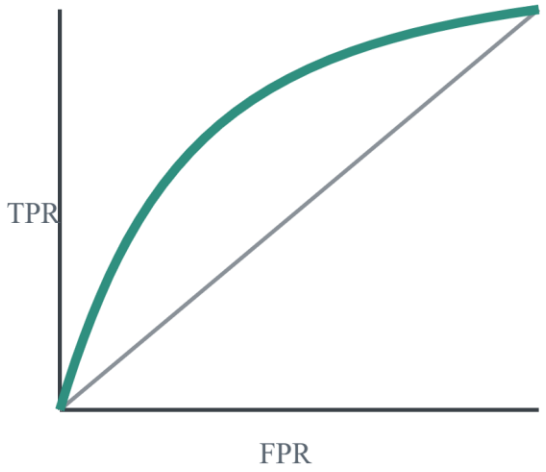
Cuando un falso positivo es más costoso: marcar un correo válido como spam, acusar a alguien inocente

Usar F1-score

Cuando ambos errores importan y las clases están desbalanceadas

2.4 — MÉTRICAS DE EVALUACIÓN

Curva ROC y AUC



La curva ROC grafica la **Tasa de Verdaderos Positivos (Recall)** contra la **Tasa de Falsos Positivos** (1 − Especificidad) al variar el umbral de decisión del modelo.

Especificidad = TN / (TN + FP)

AUC (área bajo la curva) resume el desempeño global

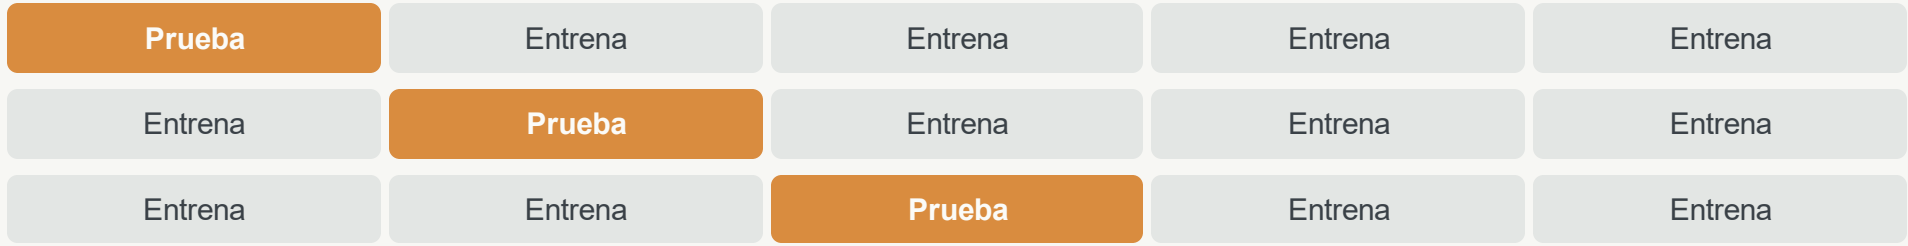
AUC = 1.0 → modelo perfecto

AUC = 0.5 → equivalente a azar (línea diagonal)

2.2 / 2.3 — VALIDACIÓN ROBUSTA

Validación cruzada (k-fold)

Una sola división entrenamiento/prueba puede dar una estimación poco confiable. La validación cruzada repite el proceso varias veces para obtener una medida más robusta y detectar sobreajuste.



… y así hasta completar las k = 5 rondas

Cómo funciona

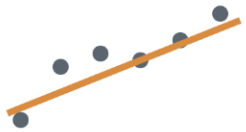
Se divide el dataset en k partes (folds). En cada ronda una parte es prueba y las demás entrenamiento; se rota hasta que todas fueron prueba una vez.

Qué revela

El promedio de las k métricas da una estimación más confiable. Una alta variación entre rondas sugiere un modelo inestable o sobreajustado.

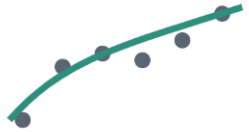
2.3 — SOBREAJUSTE / SUBAJUSTE

El equilibrio entre sesgo y varianza



Subajuste (Underfitting)

Alto sesgo: el modelo es demasiado simple y no capta el patrón. Error alto tanto en entrenamiento como en prueba.



Buen ajuste

El modelo capta la tendencia general de los datos y generaliza bien a datos nuevos.



Sobreajuste (Overfitting)

Alta varianza: el modelo memoriza el entrenamiento. Error bajo en entrenamiento, alto en datos nuevos.

2.3 — SOBREAJUSTE / SUBAJUSTE

Cómo detectarlos y mitigarlos

Mitigar el sobreajuste

- Regularización (L1 / L2)
- Validación cruzada
- Aumentar los datos de entrenamiento
- Dropout en redes neuronales
- Poda de árboles de decisión
- Early stopping (detener el entrenamiento a tiempo)

Mitigar el subajuste

- Aumentar la complejidad del modelo
- Agregar más variables (features) relevantes
- Reducir la regularización
- Entrenar por más tiempo o iteraciones

El diagnóstico se hace comparando el error o las métricas del modelo en entrenamiento vs. en prueba.

SÍNTESIS DE LA UNIDAD

Lo esencial de la Unidad II

2.1 El aprendizaje no supervisado descubre patrones sin etiquetas mediante clustering y reducción de dimensión.

2.2 La matriz de confusión compara predicciones vs. realidad y es la base de las métricas de clasificación.

2.3 El sobreajuste y el subajuste reflejan un mal equilibrio entre sesgo y varianza del modelo.

2.4 Accuracy, precision, recall, F1 y ROC/AUC permiten elegir el modelo adecuado según el problema.